



Presentación de proyecto integrador

Andres Camilo Meneses Ortega
David Hernando Monsalve Delima
Eduardo Trujillo Santos
Nicolás Cifuentes Barriga

Maestría en Arquitectura de Software, Universidad de la Sabana

Diseño y Optimización de Bases de Datos MAS 2026-3 G1G2

Miguel Alfonso Varela

2026

1. Análisis exploratorio de los datos

El proyecto integrador consiste en diseñar e implementar una arquitectura híbrida de bases de datos para Ecommify, una plataforma de comercio electrónico multivendedor especializada en productos tecnológicos. El sistema debe manejar eficientemente datos transaccionales (pedidos, pagos, inventario) y analíticos (catálogo extenso, reviews, comportamiento de usuarios).

1.1 Tabla Denormalizada: OrdersFull

El notebook de exploración construye OrdersFull mediante JOIN sucesivos de las nueve tablas del dataset. El resultado es una tabla plana con aproximadamente 50 columnas que concentra toda la información de un pedido en una sola fila. En la etapa 3 se presentará la desnormalización de la base de datos.

Grupo de columnas	Columnas representativas	Origen
Pedido	order_id, order_status, order_purchase_timestamp, order_delivered_customer_date	orders
Cliente	customer_id, customer_unique_id, customer_city, customer_state, customer_zip_code_prefix	customers
Ítem	order_item_id, shipping_limit_date, price, freight_value	order_items
Producto	product_id, product_category_name, product_weight_g, product_length_cm	products
Vendedor	seller_id, seller_city, seller_state, seller_zip_code_prefix	sellers
Pago	payment_sequential, payment_type, payment_installments, payment_value	order_payments
Reseña	review_id, review_score, review_comment_message, review_creation_date	order_reviews
Categoría	product_category_name_english	product_category

Tabla 1. Grupos de columnas en OrdersFull

1.2 Identificación de relación entre tablas

La identificación de relaciones entre tablas constituye una etapa fundamental dentro del análisis exploratorio y diseño arquitectónico de la plataforma Ecommify. A partir de la integración de las diferentes fuentes de información del dataset Brazilian E-commerce (Olist), fue posible reconocer las dependencias existentes entre entidades transaccionales y analíticas, permitiendo comprender la estructura lógica del sistema y el flujo de información entre clientes, órdenes, productos, pagos y vendedores. Este análisis resulta especialmente importante para definir una arquitectura híbrida orientada tanto a integridad referencial en PostgreSQL como a flexibilidad y consultas analíticas en MongoDB.

Tabla principal	Relación	Tabla secundaria
orders	customer_id	customers
order_items	order_id	orders
order_items	product_id	products
order_items	seller_id	sellers
order_payments	order_id	orders
order_reviews	order_id	orders
products	product_category_name	category

Tabla 2. Relación entre tablas de la base de datos ordersFull

Las relaciones identificadas evidencian una estructura altamente conectada y orientada a operaciones de comercio electrónico multivendedor. La tabla **orders** actúa como núcleo transaccional, relacionándose directamente con clientes, pagos, reviews y productos mediante tablas intermedias como **order_items**. Esta organización permite garantizar consistencia en ambientes relacionales y, simultáneamente, facilita procesos de desnormalización para escenarios analíticos. La correcta identificación de estas relaciones constituye la base para posteriores procesos de normalización, optimización e implementación de mecanismos de integridad referencial.


1.3 Análisis en la calidad de los datos y valores nulos

1.3.1 Valores nulos

El análisis de valores nulos permite evaluar la calidad e integridad de la información contenida en la base de datos **orderFull**. Este proceso resulta indispensable para identificar atributos incompletos, inconsistencias potenciales y posibles afectaciones sobre procesos transaccionales y analíticos. Además, el estudio de datos faltantes facilita la toma de decisiones relacionadas con limpieza, transformación y modelado de información dentro de la arquitectura híbrida propuesta para Ecommify.

Tabla	Filas	Columnas	Valores nulos	% nulos	Columnas con nulos
products	32951	9	2448	0.83	product_category_name, product_name_lenght, product_description_lenght, product_photos_qty, product_weight_g, product_length_cm, product_height_cm, product_width_cm
orders	99441	8	4908	0.62	order_approved_at, order_delivered_carrier_date, order_delivered_customer_date
order_items	112650	7	0	0.0	Sin nulos
order_reviews	99224	7	145903	21.01	review_comment_title, review_comment_message
customers	99441	5	0	0.0	Sin nulos
geolocation	1000163	5	0	0.0	Sin nulos
order_payments	103886	5	0	0.0	Sin nulos
sellers	3095	4	0	0.0	Sin nulos
category	71	2	0	0.0	Sin nulos

Tabla 3. Relación entre tablas de la base de datos ordersFull



Imágen 1. Cantidad de nulos en el set ordersFull

Los resultados obtenidos muestran que la mayoría de tablas presentan un alto nivel de integridad, particularmente *customers*, *order_items*, *order_payments*, *sellers* y *category*, las cuales no contienen valores nulos. Sin embargo, se identificaron porcentajes significativos de datos faltantes en *order_reviews*, especialmente en los atributos relacionados con comentarios textuales, lo que sugiere comportamiento opcional por parte de los usuarios al momento de realizar evaluaciones. Asimismo, la tabla *products* presenta valores ausentes en atributos descriptivos y dimensionales, mientras que *orders* contiene registros incompletos asociados a procesos logísticos y de entrega. Estos hallazgos evidencian la necesidad de aplicar estrategias de tratamiento de nulos y validación de calidad antes de procesos analíticos avanzados o migraciones hacia ambientes productivos.

1.3.2 Valores duplicados

La identificación de registros duplicados constituye una práctica esencial en procesos de calidad y optimización de bases de datos, debido a que la redundancia excesiva puede afectar el rendimiento de consultas, incrementar costos de almacenamiento y generar inconsistencias analíticas. En este contexto, se realizó un análisis de duplicidad sobre las tablas que conforman la estructura *orderFull*, permitiendo determinar el nivel de redundancia existente dentro del sistema transaccional y geográfico del dataset.

Tabla	Filas	Columnas	Filas duplicadas	% duplicados	Columnas con valores repetidos
customers	99441	5	0	0.0	customer_unique_id, customer_zip_code_prefix, customer_city, customer_state
geolocation	1000163	5	261831	26.18	geolocation_zip_code_prefix, geolocation_lat, geolocation_lng, geolocation_city, geolocation_state
order_items	112650	7	0	0.0	order_id, order_item_id, product_id, seller_id, shipping_limit_date, price, freight_value
order_payments	103886	5	0	0.0	order_id, payment_sequential, payment_type, payment_installments, payment_value
order_reviews	99224	7	0	0.0	review_id, order_id, review_score, review_comment_title, review_comment_message,

Tabla	Filas	Columnas	Filas duplicadas	% duplicados	Columnas con valores repetidos
					review_creation_date, review_answer_timestamp
orders	99441	8	0	0.0	order_status, order_purchase_timestamp, order_approved_at, order_delivered_carrier_date, order_delivered_customer_date, order_estimated_delivery_date
products	32951	9	0	0.0	product_category_name, product_name_lenght, product_description_lenght, product_photos_qty, product_weight_g, product_length_cm, product_height_cm, product_width_cm
sellers	3095	4	0	0.0	seller_zip_code_prefix, seller_city, seller_state
category	71	2	0	0.0	Sin duplicados

Tabla 3. Relación entre tablas de la base de datos ordersFull




Imagen 2. Cantidad de duplicados en el set ordersFull

El análisis realizado evidencia que la mayoría de tablas transaccionales mantienen una adecuada integridad y ausencia de registros completamente duplicados, lo que refleja una estructura

consistente en entidades críticas como órdenes, pagos y productos. No obstante, la tabla ***geolocation*** presenta un porcentaje considerable de duplicados, equivalente al 26.18% de sus registros, situación que puede explicarse por la reutilización de coordenadas y códigos postales en distintas ubicaciones geográficas. Aunque esta redundancia no representa necesariamente un error funcional, sí constituye un aspecto relevante para procesos de optimización, indexación y almacenamiento. En consecuencia, se recomienda evaluar estrategias de deduplicación o normalización geográfica para mejorar eficiencia en consultas espaciales y procesos analíticos.

1.3.3 Distribución temporal

El análisis de distribución temporal permite comprender el comportamiento cronológico de las operaciones realizadas dentro de la plataforma Ecommify. A través de la evaluación de fechas de compra, aprobación y entrega de órdenes, es posible identificar patrones de demanda, tendencias de crecimiento y variaciones operativas en diferentes periodos de tiempo. Este tipo de análisis resulta especialmente relevante para sistemas de comercio electrónico debido a su impacto sobre planeación logística, capacidad transaccional y escalabilidad de la arquitectura de datos.



Imagen 3. Cantidad de pedidos por mes realizados desde finales de 2016 hasta mitades de 2018




Imagen 4. Distribución de pedidos por días de la semana realizados en el histórico de ventas.



Imagen 5. Curva de pedidos realizados durante el día según la hora.


Las visualizaciones temporales realizadas evidencian una distribución dinámica de las operaciones comerciales a lo largo del tiempo, mostrando periodos de mayor actividad y crecimiento progresivo en la cantidad de pedidos procesados. Asimismo, se identifican patrones asociados a horarios y fechas específicas de mayor interacción de usuarios, lo que permite inferir comportamientos de consumo y demanda dentro de la plataforma. Estos resultados resultan fundamentales para la definición de estrategias de particionamiento, indexación temporal y optimización de consultas tanto en PostgreSQL como en MongoDB, especialmente en escenarios de alta concurrencia y procesamiento analítico.

1.3.4 Distribución geográfica

El análisis geográfico tiene como propósito identificar la distribución espacial de clientes, vendedores y operaciones comerciales dentro del ecosistema Ecommify. A partir de la información de estados, ciudades y coordenadas geográficas disponibles en el dataset, se pueden reconocer zonas de mayor concentración comercial, patrones regionales de consumo y posibles oportunidades de expansión logística. Este tipo de análisis aporta valor estratégico para arquitecturas orientadas a escalabilidad y optimización de servicios distribuidos.



Imágen 6. Cantidad de duplicados en el set ordersFull



Imágen 7. Cantidad de duplicados en el set ordersFull




Imagen 8. Cantidad de duplicados en el set ordersFull

Los resultados obtenidos evidencian una concentración significativa de operaciones en determinadas regiones y centros urbanos de Brasil, reflejando comportamientos típicos de plataformas de comercio electrónico donde las áreas metropolitanas presentan mayor volumen de clientes y transacciones. La distribución geográfica identificada permite reconocer posibles puntos críticos de demanda, optimizar estrategias de entrega y establecer criterios de particionamiento regional para consultas analíticas. Además, la integración de información espacial fortalece el potencial de MongoDB como motor analítico flexible para el manejo de grandes volúmenes de datos semiestructurados y distribuidos geográficamente.

2. Selección de arquitectura

Como parte del desarrollo del proyecto integrador para la plataforma Ecommify, el equipo realizó un análisis comparativo de las diferentes alternativas arquitectónicas propuestas, considerando las características del dataset Brazilian E-commerce (Olist), los requerimientos funcionales y no funcionales del sistema, así como las necesidades de procesamiento transaccional y analítico presentes en una plataforma de comercio electrónico multivendedor. A partir de este análisis se evaluaron aspectos relacionados con integridad de datos, flexibilidad de esquema, escalabilidad, rendimiento y capacidad de adaptación frente a diferentes tipos de información estructurada y semiestructurada.

2.1 Arquitectura Políglota Híbrida

El equipo seleccionó la Arquitectura Políglota Híbrida debido a que representa la alternativa más adecuada para abordar la diversidad y complejidad de los datos presentes en la plataforma Ecommify. El dataset analizado contiene información altamente estructurada asociada a órdenes, pagos, clientes y vendedores, la cual requiere mecanismos estrictos de integridad referencial, consistencia transaccional y normalización. Para este tipo de información, PostgreSQL ofrece ventajas significativas gracias a su cumplimiento de propiedades ACID, soporte robusto de claves foráneas, índices y capacidades avanzadas de optimización de consultas relacionales.

Por otro lado, el sistema también maneja información semi-estructurada y analítica relacionada con catálogos de productos, reviews de usuarios, descripciones textuales y posibles registros de comportamiento de navegación, cuyos esquemas pueden variar dinámicamente y presentar altos niveles de flexibilidad. En este contexto, MongoDB permite almacenar documentos JSON de manera eficiente, facilitando procesos de desnormalización, consultas analíticas y agregaciones complejas sin las restricciones de un esquema rígido relacional.

Adicionalmente, el análisis exploratorio realizado sobre la tabla desnormalizada *orderFull* evidenció múltiples relaciones entre entidades, presencia de atributos opcionales, estructuras repetitivas y datos heterogéneos, lo cual refuerza la necesidad de combinar tecnologías especializadas según la naturaleza de los datos. Mientras PostgreSQL será utilizado para garantizar consistencia y control en operaciones críticas como pedidos y pagos, MongoDB permitirá optimizar consultas analíticas relacionadas con comportamiento de usuarios, distribución geográfica, reviews y análisis temporal de operaciones.

La adopción de una arquitectura políglota híbrida también proporciona beneficios en términos de escalabilidad, flexibilidad y rendimiento, permitiendo seleccionar la tecnología más apropiada para cada caso de uso específico. Esta aproximación reduce limitaciones técnicas derivadas de utilizar un único motor de base de datos y favorece la construcción de una solución moderna alineada con las necesidades reales de plataformas e-commerce de gran volumen y alta variabilidad de información.

3. Definición de alcance específico del proyecto

3.1 Preguntas de investigación

Con el objetivo de evaluar la viabilidad y desempeño de la Arquitectura Políglota Híbrida seleccionada para la plataforma Ecommify, se formularon las siguientes preguntas de investigación orientadas a analizar el comportamiento de tecnologías relacionales y no relacionales en escenarios de comercio electrónico multivendedor:

1. ¿Cómo impacta la combinación de PostgreSQL y MongoDB en el rendimiento de operaciones transaccionales y consultas analíticas dentro de una plataforma e-commerce?
2. ¿Qué beneficios ofrece PostgreSQL en términos de integridad referencial y consistencia para la gestión de órdenes, pagos y clientes?
3. ¿Cómo mejora MongoDB el almacenamiento y procesamiento de información semi-estructurada relacionada con catálogos de productos, reviews y comportamiento de usuarios?
4. ¿Qué efectos tiene la desnormalización de datos sobre el rendimiento y escalabilidad de consultas analíticas en comparación con estructuras completamente normalizadas?
5. ¿Cómo influye la distribución temporal y geográfica de los pedidos en las estrategias de indexación, particionamiento y optimización de consultas dentro de la arquitectura híbrida?

3.2 Métricas cuantificables

Métrica	Objetivo
Tiempo de respuesta transaccional	Consultas CRUD en PostgreSQL inferiores a 100 ms
Capacidad de procesamiento	Soportar más de 100.000 pedidos y transacciones
Rendimiento analítico	Consultas analíticas en MongoDB inferiores a 2 segundos
Integridad de datos	Mantener 100% de integridad referencial entre órdenes, pagos y clientes
Disponibilidad de datos	Disponibilidad superior al 99% en ambientes de prueba
Escalabilidad	Capacidad de incorporar nuevas colecciones o atributos sin afectar operaciones existentes

Tabla 4. Métricas cuantitativas objetivo.

3.2 Limitaciones técnicas de plataformas gratuitas

Para el desarrollo del proyecto se seleccionaron herramientas gratuitas de almacenamiento, procesamiento y análisis de datos. Aunque estas plataformas ofrecen capacidades suficientes para ambientes académicos y prototipos funcionales, presentan ciertas limitaciones técnicas que deben considerarse durante el diseño e implementación de la arquitectura híbrida.

3.2.1 Supabase (PostgreSQL)

Supabase será utilizado como entorno PostgreSQL para el manejo de datos estructurados y transaccionales relacionados con órdenes, clientes, pagos e inventario. Sin embargo, la versión gratuita presenta restricciones importantes:

- Capacidad limitada de almacenamiento y procesamiento.
- Restricciones de memoria RAM y CPU compartida.
- Tiempo limitado de inactividad automática en proyectos inactivos.
- Limitaciones en concurrencia de conexiones simultáneas.
- Restricciones para cargas masivas de datos y consultas altamente complejas.
- Recursos limitados para escalabilidad horizontal y alta disponibilidad.

Estas limitaciones obligan a optimizar índices, consultas SQL y procesos ETL para evitar degradación de rendimiento.

3.2.2 MongoDB Atlas M0

MongoDB Atlas M0 será utilizado para almacenar información semi-estructurada y analítica relacionada con productos, reviews y comportamiento de usuarios. No obstante, el plan gratuito presenta las siguientes limitaciones:

- Almacenamiento limitado.
- Recursos compartidos entre múltiples usuarios.
- Restricciones de rendimiento en operaciones de agregación complejas.
- Limitaciones en throughput y operaciones por segundo.
- No incluye funcionalidades avanzadas de monitoreo y escalabilidad empresarial.
- Restricciones en backup automático y recuperación avanzada.

A pesar de estas limitaciones, MongoDB Atlas M0 resulta adecuado para pruebas de arquitectura analítica y consultas exploratorias en ambientes académicos.

3.2.3 Google Colab

Google Colab será utilizado para procesos de exploración, limpieza y análisis de datos mediante notebooks colaborativos. Sin embargo, la plataforma gratuita presenta restricciones importantes:

- Tiempo limitado de ejecución por sesión.

- Desconexión automática por inactividad.
- Recursos de CPU y memoria variables según disponibilidad.
- Restricciones en procesamiento de datasets extremadamente grandes.
- Dependencia de almacenamiento externo mediante Google Drive.
- Limitaciones para persistencia de entornos y librerías instaladas.

Estas limitaciones requieren organizar adecuadamente los procesos ETL y optimizar el manejo de memoria durante el análisis exploratorio.

3.2.3 Propuesta de cronograma inicial

Con el propósito de garantizar una correcta planificación y ejecución del proyecto integrador, se definió un cronograma estructurado que organiza las actividades relacionadas con análisis exploratorio, diseño arquitectónico, normalización, implementación y evaluación de la solución híbrida propuesta para Ecommify.

Semana	Actividad	Descripción
Semana 1	Conformación del equipo	Definición de roles, herramientas y metodología de trabajo
Semana 1	Descarga y preparación del dataset	Obtención de archivos CSV desde Kaggle y carga en Google Drive
Semana 2	Exploración y análisis de datos (EDA)	Análisis de estructura, nulos, duplicados y relaciones
Semana 2	Construcción de OrdersFull	Integración y desnormalización de tablas
Semana 3	Diseño arquitectónico	Selección y justificación de la arquitectura políglota híbrida
Semana 3	Normalización de la base de datos	Aplicación de formas normales y definición relacional
Semana 4	Implementación PostgreSQL	Creación de esquema relacional, índices y llaves foráneas
Semana 4	Implementación MongoDB	Creación de colecciones y documentos analíticos
Semana 5	Optimización y pruebas	Validación de consultas, rendimiento y métricas

Semana	Actividad	Descripción
Semana 5	Visualizaciones y análisis analítico	Distribuciones temporales y geográficas
Semana 6	Documentación final	Elaboración de informe técnico y conclusiones
Semana 6	Presentación del proyecto	Consolidación de resultados y preparación de exposición

Tabla 4. Cronograma inicial como propuesta.

Referencias

- Database System Concepts. Silberschatz, A., Korth, H. F., & Sudarshan, S. (2019). *Database System Concepts* (7th ed.). [McGraw-Hill Education](#)
- Fundamentals of Database Systems. Elmasri, R., & Navathe, S. B. (2016). *Fundamentals of Database Systems* (7th ed.). Pearson Education
- CAP theorem. Brewer, E. A. (2000). *Towards robust distributed systems*. Proceedings of the 19th Annual ACM Symposium on Principles of Distributed Computing (PODC), 7. <https://doi.org/10.1145/343477.343502>
- Designing Data-Intensive Applications. Kleppmann, M. (2017). *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. [O'Reilly Media](#)
- PostgreSQL. PostgreSQL Global Development Group. (2025). *PostgreSQL Documentation*. [PostgreSQL Official Documentation](#)
- MongoDB. MongoDB Inc. (2025). *MongoDB Manual*. [MongoDB Documentation](#)
- Supabase. Supabase. (2025). *Supabase Documentation*. [Supabase Official Documentation](#)
- Google Colab. Google. (2025). *Google Colaboratory Documentation*. [Google Colab Documentation](#)
- Brazilian E-Commerce Public Dataset by Olist. Olist. (2018). *Brazilian E-Commerce Public Dataset by Olist*. Kaggle. [Kaggle Dataset](#)